

Arquitectura de datos para el análisis de dengue

Valle del Cauca | 2023

Camilo Percy Ocampo · Maestría en Inteligencia Artificial Aplicada

Se propone un flujo de procesamiento por lotes, basado en archivos y Python, para organizar la fuente, preparar los datos y generar los indicadores del proyecto. Este documento busca recoger comentarios del grupo y acordar el enfoque antes de implementar el Taller 2.

Objetivo que orienta la arquitectura

Identificar, entre los cinco municipios del Valle del Cauca con más casos confirmados de dengue notificados del 1 de enero al 31 de diciembre de 2023, cuáles superan la proporción departamental de hospitalización, para priorizar hasta tres municipios.

Recorrido propuesto de los datos



Alcance: análisis descriptivo de notificaciones y hospitalización. La arquitectura apoya la priorización territorial; la capacidad hospitalaria y la predicción de brotes quedan fuera de esta propuesta.

Cómo se organizarían los datos

01 / Obtención y almacenes

Se propone usar el archivo histórico **Datos_2023_210.xlsx**, identificado en el Taller 1. La obtención se documentará con el portal del INS, el enlace exacto de descarga, la fecha de obtención y la versión del archivo. Para esta etapa se trabajaría con una carga del periodo 2023. [1, 3]

Almacén / formato	Contenido y uso	Referencia del Taller 1
Original Excel	Conservar la fuente en data/raw/ y registrar su procedencia.	126.411 notificaciones 69 variables
Procesado: archivo de trabajo CSV.gz	Reutilizar la selección de variables disponible en data/processed/ .	126.411 notificaciones 21 variables
Procesado: conjunto analítico Parquet propuesto	Guardar los registros elegibles, los tipos preparados y los indicadores derivados.	18.101 casos confirmados Valle del Cauca, 2023
Resultados Tablas CSV	Guardar resúmenes por municipio y mes para el notebook y el tablero.	Filas según el nivel de agrupación

Las cifras corresponden al análisis anterior y servirán para contrastar la reproducción. El archivo de 21 variables conserva todas las filas de entrada: es una selección de columnas. [1, 2]

02 / ETL: extraer, transformar y cargar

- Extraer.** Leer el Excel o el archivo de trabajo y seleccionar las variables pertinentes.
- Transformar.** Convertir fechas, interpretar edad y unidad, revisar categorías, nulos y posibles duplicados. Filtrar territorio de ocurrencia del Valle, confirmación y fechas de notificación de 2023; documentar las reglas y los registros excluidos.
- Cargar.** Guardar el conjunto preparado, el registro de controles y las tablas agregadas. Se propone ETL porque Python transforma los datos antes de guardarlos en el almacén analítico.

03 / Datos estructurados: tipos y tratamiento

Campos de ejemplo	Tipo y tratamiento previsto
CONSECUTIVE	Identificador: conservar como texto y revisar su unicidad.
FEC_NOT, FEC_HOS	Temporal: convertir a fecha y revisar coherencia.
EDAD + UNI_MED; SEMANA; ANO	Numérico: edad interpretada con su unidad; semana y año como enteros.
Departamento y municipio de ocurrencia; SEXO	Categorico: normalizar nombres y conservar los códigos territoriales.
PAC_HOS; confirmados	Categorico codificado: validar el diccionario y conservar los valores desconocidos.

Muestra y acuerdos del equipo

04 / Ejemplo real de la entrada

Cinco registros reproducidos de la vista inicial del notebook. Se muestran algunas columnas y se presentan las fechas en formato año-mes-día. Pertenecen al archivo nacional, antes de seleccionar el Valle del Cauca; cada fila representa una notificación. [1]

CONSECUTIVE	FEC_NOT	Departamento	SEXO	PAC_HOS	confirmados
10791891	2023-03-03	SANTANDER	M	2	1
10784515	2023-11-12	NARIÑO	M	2	1
10784516	2023-11-12	NARIÑO	M	2	1
10784518	2023-11-12	NARIÑO	F	2	1
10784521	2023-11-21	NARIÑO	M	2	1

Se conservan los códigos originales. El notebook usa **PAC_HOS = 1** para hospitalización y **confirmados = 1** para confirmación. Antes de implementar, se validará su interpretación con el diccionario de la fuente y se definirá el manejo de faltantes.

05 / Salida esperada

Una tabla por municipio con casos confirmados, hospitalizados, proporción de hospitalización y comparación con el valor departamental; además, una serie mensual. La selección territorial aplicará la regla del proyecto: cinco municipios con más casos y hasta tres que superen el indicador departamental.

Proporción de hospitalización (%) = 100 × casos confirmados hospitalizados / total de casos confirmados.
El valor departamental se calcula con los totales del departamento.

Comentarios que necesitamos del grupo

- 01 Alcance.** ¿Conservamos Valle del Cauca, notificaciones de 2023 y la regla de priorización del Taller 1?
- 02 Herramientas.** ¿Adoptamos archivos y ETL en Python, reutilizando el notebook y el tablero Streamlit?
- 03 Calidad.** ¿Qué reglas acordamos para códigos, datos faltantes y revisión de duplicados?
- 04 Responsables.** ¿Cómo distribuimos la revisión de la fuente, el procesamiento y la documentación final?

FUENTES Y BASE DE LA PROPUESTA

[1] Taller 1: taller1_eda_dengue.ipynb, 2 de septiembre de 2026. Objetivo, estructura, muestra y filtros del proyecto.
[2] resumen_entrega_individual_camilo.md, 2 de septiembre de 2026. Resultados previos.
[3] Instituto Nacional de Salud. Portal SIVIGILA: <https://portalsivigila.ins.gov.co/>. El enlace del archivo específico está pendiente de documentar.