

PROPUESTA PRELIMINAR · PARA REVISIÓN DEL EQUIPO

# Arquitectura de datos para el análisis de dengue

Valle del Cauca | año 2025 · Focos municipales y poblaciones

Grupo 3 · Maestría en Inteligencia Artificial Aplicada · Análisis de Datos I

Se propone un flujo de procesamiento **por lotes**, basado en archivos y **Python (ETL)**, para obtener la fuente SIVIGILA 2025, acotar el universo al **Valle del Cauca**, preparar los datos y generar los indicadores del Taller 2 (concentración municipal, ventana temporal y perfil demográfico/clínico). Esta arquitectura está alineada con el notebook `taller2_edu_dengue.ipynb` y baja el alcance del Taller 1 (nacional) a un año y un departamento.

## Objetivo que orienta la arquitectura

*En el Valle del Cauca durante 2025, identificar si un conjunto reducido de municipios (top 10) concentra al menos el **60 %** de las notificaciones de dengue, con una **ventana de pico** identificable (mes/semana) y un perfil demográfico y clínico (edad, sexo, % hospitalización, gestantes) que permita priorizar focos municipales.*

## Recorrido propuesto de los datos

| 1. Fuente                                  | 2. Almacén original                                  | 3. ETL en Python                                         | 4. Almacén procesado                            | 5. Resultados                                |
|--------------------------------------------|------------------------------------------------------|----------------------------------------------------------|-------------------------------------------------|----------------------------------------------|
| SIVIGILA evento 210<br>Datos_2025_210.xlsx | Excel en data/raw/<br>Copia íntegra +<br>procedencia | Lectura, fechas, edad,<br>filtro Valle + FEC_NOT<br>2025 | Parquet Valle limpio<br>dengue_..._valle_limpio | Tablas municipio/mes<br>Notebook + Streamlit |

**Controles de calidad en el ETL:** nulos estructurales, drop de columnas vacías (FEC\_DEF, GRU\_POB, campos militares), unicidad de CONSECUTIVE, coherencia de FEC\_NOT al año 2025, filtro de ocurrencia en Valle, features derivadas (edad\_anios, mes, hospitalizado, confirmado, gestante, grupo\_edad).

**Alcance:** análisis descriptivo/diagnóstico de notificaciones, hospitalización y poblaciones dentro del Valle. La arquitectura apoya la priorización municipal; mortalidad (FEC\_DEF nulo), IDEAM/DANE y predicción de brotes quedan fuera de esta propuesta.

01 / Obtención y almacenes

Se usa el archivo **Datos\_2025\_210.xlsx** (evento 210 — Dengue), misma familia de fuentes del Taller 1. La obtención se documenta con el portal del INS, el enlace de descarga, la fecha de obtención y la versión del archivo. El archivo es nacional (~120.5k filas); el universo analítico se obtiene filtrando **ocurrencia en Valle del Cauca** y **FEC\_NOT en 2025** (en Taller 1: ~7.4k casos / ~6.3 % del país — verificar en el notebook).

| Almacén / formato                     | Contenido y uso                                                      | Referencia Taller 2                                |
|---------------------------------------|----------------------------------------------------------------------|----------------------------------------------------|
| Original Excel                        | Conservar la fuente en data/raw/ y registrar procedencia.            | Datos_2025_210.xlsx<br>~120.5k × ~70 vars          |
| Procesado nacional Parquet (Taller 1) | Limpieza nacional opcional; no es el universo del Taller 2.          | dengue_sivigila_2025_limpio.parquet                |
| Procesado analítico Parquet Valle     | Registros elegibles Valle 2025 + tipos + features derivadas.         | dengue_sivigila_2025_valle_limpio.parquet          |
| Resultados Tablas / notebook          | Resúmenes por municipio, mes, semana, sexo, grupo etario, gestantes. | taller2_eda_dengue.ipynb<br>(+ Streamlit opcional) |

El parquet del Valle **no pisa** el parquet nacional del Taller 1. El archivo de trabajo conserva trazabilidad desde la fuente original.

02 / ETL: extraer, transformar y cargar

**Extraer.** Leer el Excel 2025 desde data/raw/ (utilidad load\_dengue, modo year=2025) y seleccionar variables pertinentes al SMART (tiempo, territorio de ocurrencia, demografía, PAC\_HOS, confirmados, GP\_GESTAN, sem\_ges).

**Transformar.** Parsear fechas SIVIGILA; filtrar FEC\_NOT ≠ 2025; normalizar edad con UNI\_MED → edad\_anios; derivar mes, hospitalizado, confirmado, gestante, grupo\_edad; filtrar Departamento\_ocurrencia = Valle del Cauca; documentar registros excluidos y nulos estructurales (FEC\_HOS, sem\_ges).

**Cargar.** Guardar el conjunto Valle preparado en Parquet, generar tablas agregadas (municipio, mes/semana, perfil demográfico) y alimentar el notebook / tablero. Se elige **ETL** (no ELT) porque Python transforma antes de materializar el almacén analítico.

03 / Datos estructurados: tipos y tratamiento

| Campo(s)                                      | Tipo y tratamiento previsto                                          |
|-----------------------------------------------|----------------------------------------------------------------------|
| CONSECUTIVE                                   | Identificador: conservar; revisar unicidad.                          |
| FEC_NOT, INI_SIN, FEC_HOS                     | Temporal: convertir a datetime; acotar FEC_NOT a 2025.               |
| EDAD + UNI_MED; SEMANA; ANO                   | Numérico: edad_anios; semana/año enteros.                            |
| Departamento_ocurrencia; Municipio_ocurrencia | Categorico: filtro Valle; municipio = unidad de foco (H2).           |
| SEXO; AREA; grupo_edad                        | Categorico: perfil poblacional (H3).                                 |
| PAC_HOS; confirmados; GP_GESTAN               | Categorico codificado → flags hospitalizado / confirmado / gestante. |
| sem_ges                                       | Numerico; nulo estructural fuera de gestantes.                       |

04 / Ejemplo real de la entrada

Muestra ilustrativa de columnas clave del archivo nacional **antes** del filtro Valle (cada fila = una notificación). Los códigos originales se conservan: PAC\_HOS = 1 hospitalizado; confirmados = 1 confirmado; GP\_GESTAN = 1 gestante. Fechas en formato año-mes-día tras el parseo.

| CONSECUTIVE | FEC_NOT    | Depto. ocurrencia | Municipio    | SEXO | PAC_HOS | confirmados |
|-------------|------------|-------------------|--------------|------|---------|-------------|
| 23659       | 2025-03-30 | ARAÚCA            | ...          | F    | 2       | 1           |
| ...         | 2025-01-15 | VALLE             | CALI         | M    | 1       | 1           |
| ...         | 2025-02-03 | VALLE             | PALMIRA      | F    | 2       | 1           |
| ...         | 2025-01-22 | VALLE             | BUENAVENTURA | M    | 2       | 0           |
| ...         | 2025-04-10 | VALLE             | TULUÁ        | F    | 1       | 1           |

Tras el ETL, el almacén analítico contiene solo filas con ocurrencia en Valle y FEC\_NOT en 2025, más las features derivadas usadas en el EDA (H1–H3).

05 / Salida esperada

Tablas y gráficas por municipio (casos, % Valle, % acumulado, % hospitalización, edad mediana, n gestantes); series por mes y semana epidemiológica; perfil por sexo y grupo\_edad; comparación gestantes vs otras mujeres. La meta SMART se evalúa con el share del top 10 municipal  $\geq 60\%$ .

***Proporción de hospitalización (%)** =  $100 \times \text{casos hospitalizados} / \text{total de casos del nivel (municipio, Valle o grupo)}$ .*

Acuerdos del equipo y criterios de la entrega

La rúbrica del Taller 2 exige describir cómo se obtienen los datos, los **almacenes**, el enfoque **ETL/ELT**, los **tipos de datos** y una **muestra**. Esta propuesta cubre esos puntos y se incrusta también en el notebook (sección de arquitectura).

| Tema         | Acuerdo propuesto                                                                                                   |
|--------------|---------------------------------------------------------------------------------------------------------------------|
| Alcance      | Valle del Cauca, notificaciones 2025, priorización municipal (top 10 / 60 %) y poblaciones (edad, sexo, gestantes). |
| Herramientas | Archivos + ETL en Python; notebook taller2_eda_dengue.ipynb; Streamlit opcional.                                    |
| Calidad      | Drop columnas ~100 % nulas; dropna en COD_MUN_O y FEC_NOT; no imputar FEC_HOS ni sem_ges; documentar exclusiones.   |
| ETL vs ELT   | ETL: transformar en Python antes de materializar el Parquet Valle.                                                  |
| Responsables | Fuente/procedencia; pipeline de limpieza; EDA e interpretación; documentación PDF + notebook.                       |

FUENTES Y BASE DE LA PROPUESTA

[1] Notebook Taller 2: notebooks/taller2\_eda\_dengue.ipynb — SMART, hipótesis H1–H3, limpieza y EDA Valle 2025.  
[2] Notebook Taller 1: notebooks/taller1\_eda\_dengue.ipynb — perfil nacional y contraste Valle vs país.  
[3] Propuesta previa del equipo (Valle 2023): docs/Propuesta\_arquitectura\_datos\_dengue.pdf — se actualiza aquí a 2025.  
[4] Instituto Nacional de Salud — Portal SIVIGILA: <https://portalsivigila.ins.gov.co/>